

Laporan Praktikum Kontrol Cerdas

Minggu ke - 4

Nama : Mutiara Sekarayu Apriansyah
NIM : 224308042
Kelas : TKA-6B
Akun Github : <https://github.com/Mutsee>
Student Lab Assistant : Mas Alfian

1. Judul Percobaan: *Reinforcement Learning for Autonomous Control with DQN*

2. Tujuan Percobaan:

- Memahami konsep dasar Reinforcement Learning (RL) dalam sistem kendali.
- Mengimplemtasikan agen RL menggunakan algoritma *Deep Q-Network* (DQN).
- Menggunakan OpenAI Gym sebagai simulasi lingkungan untuk pelatihan RL.
- Melatih dan menguji agen RL untuk mengontrol lingkungan secara otonom.
- Menggunakan GitHub untuk version control dan dokumentasi praktikum.

3. Landasan Teori:

Reinforcement Learning adalah algoritma yang mengumpulkan pengetahuan (sinyal penguatan) untuk memilih tindakan yang mengarah ke hasil tertinggi yang diharapkan. Kemampuan *reinforcement learning* untuk secara mandiri menjelajahi lingkungan yang sangat dinamis dan stokastik dan mengembangkan, dengan mengumpulkan umpan balik evaluatif dari lingkungan, kebijakan kontrol yang optimal (Karimah, 2023). Tidak seperti *machine learning* yang membutuhkan dataset untuk proses training, pada *reinforcement learning* agen akan mengeksplorasi lingkungannya dan membuat keputusan berdasarkan nilai reward dan punishment yang diberikan

ketika agen melakukan suatu aksi (**Kurniawati dkk., 2021**). Setelah proses trial dan error, agen akan mempelajari aksi apa yang harus dilakukan untuk mendapatkan reward dengan nilai tertinggi. Sehingga agen akan memiliki kecenderungan untuk mengambil aksi tersebut jika berada pada suatu kondisi tertentu. *Epsilon greedy* merupakan salah satu algoritma yang digunakan untuk *learning process*. Algoritma ini menyeimbangkan proses eksploitasi dan eksplorasi berdasarkan nilai epsilon. Ketika agen melakukan eksplorasi lingkungan, agen akan mengambil aksi acak tanpa mempedulikan nilai reward atau punishment yang didapatkan, sedangkan ketika agen berada dalam mode eksploitasi, maka agen akan melakukan aksi yang memberikan nilai reward tertinggi (**Liu dkk., 2022**). Epsilon dalam hal ini merupakan parameter yang menentukan apakah agen akan melakukan eksplorasi atau eksploitasi. Pada praktikum ini dengan mengimplemtasikan agen RL menggunakan algoritma *Deep Q-Network* (DQN). DQN adalah algoritma RL yang menggabungkan algoritma *Q-Learning* dengan *Deep Neural Network* (**Putra dkk., 2024**). *Q-Learning* dikategorikan dalam metode model-free yang tidak membutuhkan informasi yang lengkap tentang kondisi *environment*. Berbeda dengan metode *model-based*, *Q-Learning* memungkinkan agen untuk berada satu langkah ke depan. Agen berada dalam keadaan tertentu, mengambil tindakan tertentu, dan menerima value berdasarkan tindakan tersebut. Pada DQN, DNN digunakan untuk memodelkan nilai value tersebut dengan menggunakan *Neural Network*.

4. Analisis dan Diskusi:

- Analisis

Pada **CartPole-v1**, tugas agen adalah menjaga keseimbangan tiang di atas gerobak/kotak selama mungkin. Lingkungan ini memberikan reward sebesar +1 untuk setiap langkah yang berhasil mempertahankan keseimbangan, sehingga proses pembelajaran dapat berlangsung lebih cepat. Dengan *epsilon decay yang relatif cepat (0.995)*, agen lebih cepat beralih dari **eksplorasi** ke **eksploitasi**, yang mempercepat konsistensi pengambilan keputusan berdasarkan pengalaman sebelumnya. **Replay buffer sebesar 2000** untuk menangani kompleksitas lingkungan ini, karena setiap episode memberikan banyak pengalaman yang dapat

dipelajari dalam waktu singkat. Selain itu, batas maksimal episode 1000 membuat agen memiliki banyak kesempatan untuk belajar dan menyempurnakan kebijakan yang lebih optimal.

Sebaliknya, **MountainCar-v0** menghadirkan tantangan yang lebih besar karena agen harus menggerakkan mobil melewati bukit/gunung dengan cara mengayun bolak-balik untuk mendapatkan momentum yang cukup. Tantangan utama pada lingkungan ini adalah sistem *reward*-nya yang lebih menantang, di mana agen hanya mendapatkan ***reward* yang signifikan (+100) jika berhasil mencapai puncak**, sementara langkah-langkah lainnya menghasilkan ***reward* negatif** yang membuat agen lebih sulit memahami strategi yang benar. Oleh karena itu, parameter ***epsilon decay* diperkecil (0.999)** agar agen tetap mengeksplorasi lebih lama sebelum akhirnya mulai mengeksploitasi strategi yang sudah ditemukan. Selain itu, ***replay buffer* diperbesar menjadi 5000** untuk menyimpan lebih banyak pengalaman yang dapat membantu agen memahami pola pergerakan yang lebih kompleks. Dengan batas **maksimal 200 langkah per episode**, agen harus belajar lebih cepat untuk mencapai solusi optimal dalam ruang tindakan yang lebih terbatas dibandingkan dengan CartPole.

- Diskusi

Perbedaan dalam hasil pembelajaran pada **CartPole-v1** dan **MountainCar-v0** menunjukkan bahwa setiap lingkungan memiliki karakteristik unik yang mempengaruhi strategi pelatihan agen. **CartPole-v1** lebih mudah dipelajari karena memiliki sistem *reward* yang langsung memberikan umpan balik positif untuk tindakan yang benar. Oleh karena itu, pendekatan eksplorasi yang lebih cepat dapat membantu agen belajar lebih efisien. Sebaliknya, **MountainCar-v0** memerlukan strategi yang lebih sabar karena *reward* hanya diperoleh secara signifikan saat mencapai tujuan. Selain itu, perbedaan dalam struktur *reward* mempengaruhi efektivitas teknik *Experience Replay* dan *Target Network Update*. Pada **CartPole**, *replay buffer* yang lebih kecil sudah cukup karena lingkungan memberikan banyak pengalaman positif dalam waktu singkat. Namun,

pada **MountainCar**, *replay buffer* yang lebih besar diperlukan agar agen memiliki lebih banyak sampel untuk memahami strategi jangka panjang.

Dari hasil ini, dapat disimpulkan bahwa pendekatan *reinforcement learning* tidak bisa diterapkan secara seragam pada semua lingkungan. Setiap lingkungan memiliki karakteristik unik yang menuntut penyesuaian parameter agar agen dapat belajar secara optimal.

5. Assignment:

Pada praktikum minggu keempat ini, telah dilakukan implementasi dan perbandingan performa agen *Deep Q-Network* (DQN) pada dua lingkungan berbeda, yaitu **CartPole-v1** dan **MountainCar-v0** menggunakan pustaka **OpenAI Gym** dan **TensorFlow**. Agen DQN yang digunakan memiliki dua *neural network* utama, yaitu *Q-Network* untuk menentukan aksi optimal berdasarkan kondisi lingkungan dan *Target Network* yang diperbarui secara berkala untuk stabilisasi pelatihan. Selain itu, agen juga menerapkan *Experience Replay* menggunakan *buffer* untuk menyimpan pengalaman sebelumnya dan meningkatkan efisiensi pembelajaran.





Pada eksperimen pertama dengan **CartPole-v1**, agen bertugas menjaga keseimbangan tiang di atas gerobak/kotak selama mungkin. Agen mendapatkan *reward* +1 setiap langkah, sehingga umpan balik yang sering memungkinkan pembelajaran lebih cepat. Parameter seperti *epsilon decay* (0.995), *replay buffer* (2000), dan *batch size* (64) telah disesuaikan agar eksplorasi berkurang lebih cepat dan agen dapat fokus mengeksploitasi kebijakan yang sudah dipelajari. Hasil pelatihan menunjukkan bahwa agen dapat meningkatkan skornya secara bertahap dan belajar menjaga keseimbangan tiang lebih lama seiring berjalannya waktu.



Sedangkan, eksperimen kedua dilakukan pada **MountainCar-v0**, yang memiliki tantangan lebih besar karena agen harus menggerakkan mobil untuk mencapai puncak bukit dengan memanfaatkan momentum. Tidak seperti *CartPole*, *reward* hanya diberikan jika agen berhasil mencapai puncak, sehingga strategi eksplorasi menjadi lebih sulit. Oleh karena itu, beberapa parameter diubah, seperti *epsilon decay* yang lebih lambat (0.999), *replay buffer* yang lebih besar (5000), dan tambahan *reward* +100 ketika berhasil

mencapai tujuan. Hal ini bertujuan untuk memberi agen lebih banyak kesempatan untuk menemukan strategi optimal sebelum memasuki fase eksploitasi. Dengan perubahan ini, agen dapat secara bertahap belajar menggunakan momentum untuk mencapai puncak meskipun membutuhkan waktu lebih lama dibandingkan dengan CartPole.

Secara keseluruhan, tugas ini menunjukkan bagaimana pemilihan parameter dalam *reinforcement learning* sangat bergantung pada karakteristik lingkungan. Lingkungan dengan *reward* yang lebih sering, seperti CartPole, memungkinkan agen belajar lebih cepat dengan *epsilon decay* yang lebih cepat dan *replay buffer* yang lebih kecil. Sebaliknya, lingkungan dengan *reward* yang jarang seperti MountainCar, membutuhkan eksplorasi yang lebih lama dan *replay buffer* yang lebih besar agar agen dapat mengumpulkan pengalaman yang cukup untuk menemukan strategi yang efektif.

6. Data dan Output Hasil Pengamatan:

No.	Variabel	Hasil Pengamatan	
		CartPole-v1	MountainCar-v0
1.	Waktu Pelatihan	CartPole lebih cepat mencapai performa optimal dalam beberapa ratus episode	MountainCar tetap membutuhkan lebih banyak waktu untuk mencapai keberhasilan yang stabil
2.	Jumlah Episode Maksimum	CartPole dilatih hingga 1000 episode <pre># ENVIRONMENT: CartPole-v1 env = gym.make("CartPole-v1", state_size = env.observation_ action_size = env.action_spac agent = DQNAgent(state_size, for e in range(1000): state, _ = env.reset() state = np.reshape(state,</pre>	MountainCar dilatih hingga 1000 episode <pre># ENVIRONMENT: MountainCar-v0 env = gym.make("MountainCar-v0 state_size = env.observation_s action_size = env.action_space agent = DQNAgent(state_size, a for e in range(1000): state, _ = env.reset() state = np.reshape(state,</pre>
3.	Skor Awal dan Maksimum	Skor bervariasi tergantung seberapa lama tiang tetap seimbang 	Skor awal mencapai 199 karena maksimal langkah dalam satu episode adalah 200 
4.	<i>Epsilon</i>	Nilai epsilon (ϵ) menurun seiring dengan proses agen 	Nilai epsilon (ϵ) menurun seiring dengan proses agen 

5.	Kinerja Agen	Kinerja yang lebih stabil dengan skor yang lebih tinggi	Masih menghadapi tantangan dalam mencapai puncak
6.	Kondisi Berhasil	Episode berakhir jika tiang jatuh atau batas langkah maksimum tercapai	Episode berakhir jika mobil mencapai puncak bukit (flag)
7.	Hasil		

7. Kesimpulan:

Berdasarkan praktikum dan analisis yang telah dilakukan, maka dapat diambil kesimpulan yaitu:

- CartPole-v1 lebih cepat dipelajari karena memberikan *reward* di setiap langkah, sehingga agen dapat dengan cepat memahami strategi optimal.
- MountainCar-v0 lebih sulit dipelajari karena *reward* hanya diberikan saat mencapai puncak bukit, memerlukan strategi eksplorasi lebih lama, dan mengandalkan momentum untuk berhasil.
- Penggunaan *target network* membantu stabilitas pembelajaran, menghindari perubahan nilai Q yang terlalu drastis.
- *Experience Replay* meningkatkan efisiensi pembelajaran, tetapi ukuran buffer harus disesuaikan dengan kompleksitas lingkungan agar tetap efektif.
- *Hyperparameter* sangat menentukan keberhasilan agen, sehingga perlu disesuaikan dengan karakteristik lingkungan untuk hasil optimal.

8. Saran:

Untuk meningkatkan performa agen DQN pada lingkungan yang lebih kompleks, disarankan untuk menyesuaikan parameter lebih lanjut melalui eksperimen, seperti menggunakan *dueling DQN*, *prioritized experience replay*, atau peningkatan arsitektur jaringan dengan lebih banyak neuron atau lapisan. Selain itu, untuk kasus seperti MountainCar, pendekatan lain seperti *actor-critic methods* atau *policy-based reinforcement learning* dapat dicoba untuk

meningkatkan efisiensi pembelajaran. Lebih jauh, penggunaan *hardware* yang lebih kuat seperti GPU dapat mempercepat proses pelatihan, terutama pada lingkungan dengan kompleksitas tinggi.

9. Daftar Pustaka:

- Karimah Tauhid, Volume 2 Nomor 1 (2023), e-ISSN 2963-590X. (2023). 2.
- Kurniawati, N., Ningsih, Y. K., Puspa, S. D., & Adi, T. S. (2021). Algoritma Epsilon Greedy pada Reinforcement Learning untuk Modulasi Adaptif Komunikasi Vehicle to Infrastructure (V2I). *ELKOMIKA: Jurnal Teknik Energi Elektrik, Teknik Telekomunikasi, & Teknik Elektronika*, 9(3), 716. <https://doi.org/10.26760/elkomika.v9i3.716>
- Liu, F., Viano, L., & Cevher, V. (t.t.). Understanding Deep Neural Function Approximation in Reinforcement Learning via ϵ -Greedy Exploration.
- Putra, R. A., Syahbana, Y. A., & Ananda. (2024). Implementasi Algoritma Deep Q-Network (DQN) pada Lampu Lalu Lintas Adaptif Berdasarkan Waktu Tunggu dan Arus Kendaraan. *The Indonesian Journal of Computer Science*, 13(5). <https://doi.org/10.33022/ijcs.v13i5.4372>